

## 4. dplyr패키지



데이터 정제작업과 조작을 위한 dplyr패키지 주요함수 설명



## I. dplyr패키지 개요

- Hadley Wickham이 작성한 패키지
- 비정형 데이터의 요약과 정제작업을 쉽게 빠르게 수행할 수 있음
- 데이터 조작을 수행하기 위한 다양한 함수들을 제공
- 벡터보다는 데이터 프레임 처리에 적합한 함수들로 구성

## + 참고) SQL과 비교

- SQL – 데이터 쿼리와 관리를 위한 언어
- dplyr – 데이터분석을 위해 디자인된 패키지 – Mysql, PostgreSQL, SQLite, BigQuery 를 지원

dplyr함수	유사한 SQL명령	기능
select( )	Select	컬럼 선택
filter()	where	행을 필터링(서브셋)
group_by()	Group by	데이터 그룹화
summarise() / aggregate()		데이터 요약 / 집계
arrange()	Order by	데이터 정렬
join()	JOIN	데이터프레임 조인
mutate()	Column alias	새로운 변수 생성

## □ dplyr 패키지 설치 및 기본함수 익히기

```
> install.packages("dplyr")
--- 현재 세션에서 사용할 CRAN 미러를 선택해 주세요 ---
'bindr', 'assertthat', 'bindrcpp', 'glue', 'pkgconfig', 'BH', '$
```

### 1. distinct() → 데이터 셋에서 중복된 행을 제거

- distinct(데이터셋) → 데이터셋의 모든 항목에 대해 중복체크
  - distinct(데이터셋, 중복체크열, 옵션) → 특정 열에 대한 중복체크
- 중복된 행을 제거

```
> df<-read.csv("d:\\mining-r\\exdata.csv",header=TRUE)
> result2<-distinct(df,Index,.keep_all=TRUE)
> result2
```

	Index	State	Y2002	Y2003	Y2004	Y2005	Y2006	Y2007
1	A	Alabama	1296530	1317711	1118631	1492583	1107408	1440134
2	C	California	1685349	1675807	1889570	1480280	1735069	1812546
3	D	Delaware	1330403	1268673	1706751	1403759	1441351	1300836
4	F	Florida	1964626	1468852	1419738	1362787	1339608	1278550
5	G	Georgia	1929009	1541565	1810773	1779091	1326846	1223770
6	H	Hawaii	1461570	1200280	1213993	1245931	1459383	1430465

다른 열은 영향받지 않음

Index열에 대해 중복된 데이터 찾아서 제거



## 2. select() – 특정 열을 추출

• select(데이터셋, 추출할 열) → 해당 데이터 셋에서 추출할 열을 기술

```
> result3<-select(df, State, Y2013:Y2015)
```

df에서 State, y2013~y2015까지 열을 추출

```
> result3
```

	State	Y2013	Y2014	Y2015
1	Alabama	1852841	1558906	1916661
2	Alaska	1985302	1580394	1979143
3	Arizona	1363279	1525866	1647724
4	Arkansas	1591896	1360959	1329341
5	California	1156536	1388461	1644607
6	Colorado	1178355	1383978	1330736

## 3. filter() – 사용자가 원하는 조건에 맞는 데이터 서브셋 구성함수

• 기본형식- filter(데이터셋, 조건)

• 데이터프레임 → 값이 를 만족하는 행만 모두 추출

```
> f1<-filter(df, Index %in% c('A', 'D'))
```

df에서 Index열의 값이 'A','D'를 만족하는 모든 행을 추출

```
> f1
```

	Index	State	Y2002	Y2003	Y2004	Y2005	Y2006
1	A	Alabama	1296530	1317711	1118631	1492583	1107408
2	A	Alaska	1170302	1960378	1818085	1447852	1861639
3	A	Arizona	1742027	1968140	1377583	1782199	1102568
4	A	Arkansas	1485531	1994927	1119299	1947979	1669191
5	D	Delaware	1330403	1268673	1706751	1403759	1441351
6	D District of Columbia		1111437	1993741	1374643	1827949	1803852



```
> f2<-filter(df,Index %in% c('A','D') & Y2015<1640000)
> f2
```

df에서 Index열의 값이 'A','D'를 만족하고 and,Y2015 값이 1640000미만을 만족하는 모든 행을 추출

	Index	State	Y2002	Y2003	Y2004	Y2005	Y2006	Y2007
1	A	Arkansas	1485531	1994927	1119299	1947979	1669191	1801213
2	D	Delaware	1330403	1268673	1706751	1403759	1441351	1300836
3	D District of Columbia		1111437	1993741	1374643	1827949	1803852	1595981
	Y2008	Y2009	Y2010	Y2011	Y2012	Y2013	Y2014	Y2015
1	1188104	1628980	1669295	1928238	1216675	1591896	1360959	1329341
2	1762096	1553585	1370984	1318669	1984027	1671279	1803169	1627508
3	1193245	1739748	1707823	1353449	1979708	1912654	1782169	1410183

```
> f4<-filter(df,grepl("Ne",State))
> f4
```

grepl() -->grepl(패턴,텍스트) → 텍스트에서 특정 패턴을 찾아냄.

	Index	State	Y2002	Y2003	Y2004	Y2005	Y2006	Y2007
1	N	Nebraska	1885081	1309769	1425527	1240465	1500594	1278272
2	N	Nevada	1426117	1114500	1119707	1758830	1694526	1765826
3	N	New Hampshire	1419776	1854370	1195119	1990062	1645430	1286967
4	N	New Jersey	1605532	1141514	1613550	1181452	1541327	1156804
5	N	New Mexico	1819239	1226057	1935991	1124400	1723493	1475989
6	N	New York	1395149	1611371	1170675	1446810	1426941	1463171

## 4. summarise() 함수 - 데이터 셋으로부터 특정 컬럼을 요약집계하는 함수

- 기본형식- summarise(데이터셋, 집계열변수명=집계함수(대상열))

- 데이터프레임 → 데이터를 합산하여 결과를 열에 표시

```
> summarise(df, 평균치2002=mean(Y2002))
  평균치2002
1      1566034
> |
```

복수의 열에 대해서 평균과 표준편차를 일괄적으로 계산

```
> summarise_at(df, vars(Y2011:Y2015), funs(mean, sd))
  Y2011_mean Y2012_mean Y2013_mean Y2014_mean Y2015_mean Y2011_sd Y2012_sd
1    1574968    1591135    1530078    1583360    1588297  265721.6  283767.5
  Y2013_sd Y2014_sd Y2015_sd
1  282729.9  260155.4  274380.7
```

## 5. arrange()함수 - 데이터 정렬함수

- 기본형식- arrange(데이터셋, 정렬할 대상열)

- 데이터프레임 → 데이터를 오름차순 정렬
- 내림차순 정렬 사용 → 데이터 내림차순 정렬

```
> arrange(df1, Index, desc(Y2002))
```

Index열 중심으로 오름차순 정렬하고, 같은 경우  
Y2002 값이 큰 순서부터 표시되도록 정렬

	Index	State	Y2002	Y2003	Y2004	Y2005	Y2006
1	A	Arizona	1742027	1968140	1377583	1782199	1102568
2	A	Arkansas	1485531	1994927	1119299	1947979	1669191
3	A	Alabama	1296530	1317711	1118631	1492583	1107408
4	A	Alaska	1170302	1960378	1818085	1447852	1861639
5	C	California	1685349	1675807	1889570	1480280	1735069
6	C	Connecticut	1610512	1232844	1181949	1518933	1841266



## 6. group\_by()함수 - 특정 열을 중심으로 데이터를 그룹화 함.

- 기본형식- group\_by(데이터셋, 그룹화할 대상열)

- 데이터프레임 → 별로 그룹화하겠다는 의미

```
> a=df1 %>% group_by(Index) %>% summarise(avg=mean(Y2015,na.rm=TRUE))
> a
# A tibble: 10 x 2
  Index      avg
  <fctr>   <dbl>
1      A 1718217
2      C 1564472
3      D 1518846
4      F 1170389
5      G 1725470
6      H 1150882
7      I 1612542
8      K 1649439
9      L 1403857
10     M 1794366
> |
```

%>% 파이프 연산자

df1 대상으로 Index별로 그룹화 하고,y2015 평균을 계산한 후에 결과 보여줌



## 7. mutate() 함수 - 새로운 변수를 생성

- 기본형식—mutate(데이터셋, 추가할 변수명=식)

- 데이터프레임 → 에서 값을 뺀 차이를 에 저장

```
> a1<-mutate(df1,differ=Y2015-Y2014)
> a2<-filter(a1,differ>300000)
> a2
```

	Index	State	Y2002	Y2003	Y2004	Y2005	Y2006	Y2007	Y2008
1	A	Alabama	1296530	1317711	1118631	1492583	1107408	1440134	1945229
2	A	Alaska	1170302	1960378	1818085	1447852	1861639	1465841	1551826
3	M	Maine	1582720	1678622	1208496	1912040	1438549	1330014	1295877
4	M	Minnesota	1729921	1675204	1903907	1561839	1985692	1148621	1328133
5	M	Mississippi	1983285	1292558	1631325	1943311	1354579	1731643	1428291
	Y2009	Y2010	Y2011	Y2012	Y2013	Y2014	Y2015	differ	
1	1944173	1237582	1440756	1186741	1852841	1558906	1916661	357755	
2	1436541	1629616	1230866	1512804	1985302	1580394	1979143	398749	
3	1969163	1627262	1706080	1437088	1318546	1116792	1529233	412441	
4	1890633	1995304	1575533	1910216	1972021	1515366	1864553	349187	
5	1568049	1383227	1629132	1988270	1907777	1649668	1991232	341564	

```
>
```

y2015-y2014를 계산하여 differ변수 생성  
differ값이 300000초과하는 데이터 행을 추출