

6. 트윗데이터 전처리



트윗데이터를 읽어온 후 기본 전처리 과정을 진행해보아요.

I. 트윗 데이터 읽어온 후 정제작업

- ◆ 트위터에 접속하여 “present”라는 검색어를 입력하여 트윗데이터 1000건을 읽어온 후 불필요한 태그와 url을 제거한 후 단어단위로 빈도를 분석해보는 작업을 함께 해보죠.

필요한 패키지를 설치하고 트위터 연결작업부터 실행해요.



```
install.packages(c("twitteR", "dplyr"))
library(twitteR)
library(dplyr)
Sys.setenv(JAVA_HOME="c:\\\\program files\\\\java\\\\jdk1.8.0_141")
install.packages("KoNLP")
library(KoNLP)
api_key <- "fxd8VtG22tTN25KvQLiF5DjfE"
api_secret <- "nAhcVYDk4aGv1D5W4Hr5GizSsbKEafy2LmiUJ0PYbxpufTh6xY"
access_token <- "257325922-KAH1Gd0i2Z4jwDRGDIgkv024eJN3MwyrmrZ3gYoJH"
access_token_secret <- "P8ap67uUllyXc45A10PwSRhdzcaMpbAxBNDsT8ujBA7e4"
setup_twitter_oauth(api_key, api_secret, access_token, access_token_secret)
```

```
> library(dplyr)
```

다음의 패키지를 부착합니다: 'dplyr'

The following objects are masked from 'package:twitteR':

id, location

The following objects are masked from 'package:stats':

filter, lag

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
> api_key <- "fxd8VtG22tTN25KvQLiF5DjfE"
```

```
> api_secret <- "nAhcVYDk4aGv1D5W4Hr5GizSsbKEafy2LmiUJ0PYbxp
```

```
> access_token <- "257325922-KAH1Gd0i2Z4jwDRGDIgkv024eJN3Mwy
```

```
> access_token_secret <- "P8ap67uUllyXc45A10PwSRhdzcaMpbAxBN
```

```
> setup_twitter_oauth(api_key, api_secret, access_
```

```
[1] "Using direct authentication"
```

```
> |
```

HOWTO 1) 트위터에 검색어 “present”입력하여 1000개의 트윗을 가져와서 확인하는 작업을 그림처럼 실행해보아요.

```
> msg_tweet<-searchTwitter(enc2utf8("새해"),n=1000,lang="ko")
> head(msg_tweet)
[[1]]
[1] "xoskiz: RT @Stray_Kids: [SPOT KIDS]\n새해맞이 Stray Kids 랜덤 선물 TIME !\n\n호기심이 많은 삼공즈는\n$"

[[2]]
[1] "dokdotea: RT @Jaemyung_Lee: &lt; 예산은 충분한데도 성남은 자유한국당과 바른정당 시의원들이 극력반대입$

[[3]]
[1] "Wanna19991102: RT @_deockjil_: 재활초커 겸 새해 겸 옹넬환 예능겸 완간 기원하면서 존잘임과 합작으로 제$

[[4]]
[1] "gwirlgroups: RT @10_PRISTIN: [나영] 하이를~새해복많이받으세염ㅎㅎ\new 무대한날 셀카 빠밤 https://t.co/$

[[5]]
[1] "hscw0526: @woo_gun1122 혹여 현생이 바쁘신거라면 그에 부응할수있는 성과를 꼭 이루셨으면 좋겠어요 :) 부$

[[6]]
[1] "Nuqlear__: RT @maboo_chu: 아침에 일어나면 밤사이에 육백명의 회원들로부터 단톡방에 몇백통의 냉짤이 올$"

> class(msg_tweet)
[1] "list"
> length(msg_tweet)
[1] 1000
```



2) 트윗의 자료구조형태가 리스트이므로, 이를 데이터프레임 구조로 변경한 다음 중복된 트윗내용에 대해 제거하는 작업을 그림처럼 코딩해보죠.

```
> df<-twListToDF(msg_tweet)
> class(df)
[1] "data.frame"
> df1<-distinct(df, text)
>
```

트윗을 읽어오면 list형태인데요. 이를 데이터프레임으로 변경할 때
twListTiDF()함수를 이용해요.

3) 그림처럼 TEXT를 실행해보면 중복제거된 트윗 내용을 볼 수 있어요. 그럼, 여기서 우리가 분석할 실제 텍스트는?

```
txt<-df1$text  
txt
```



정리) 정규표현식 이용한 문자열처리

▶ 정규표현식 – 문자열 처리를 유연하게 하기위한 기법

여러 프로그래밍 언어에서 공통적으로 문자열 매칭/치환에 사용

* 주요 정규표현식 기본정리

표현식	설명	\w	알파벳이나 숫자
^	문자열 시작	\W	알파벳이나 숫자를 제외한 문자
\$	문자열 종료	\P	숫자[0~9]와 동일
*	앞 문자가 없을 수도 무한정 많을 수도 있음.	\D	숫자를 제외한 모든 문자
+	앞문자가 하나 이상	\특수문자	해당 특수문자를 의미
?	앞 문자 없거나 하나 있음		
[]	문자집합이나 범위를 나타내며, 두 문자 사이에는 – 기호로 범위표시		
{}	횟수 또는 범위를 나타냄		
()	소괄호 안의 문자를 하나의 문자로 인식		
	패턴 안에서 or 연산을 수행할 때 사용		
\s	공백문자		
\S	공백문자가 아닌 나머지 문자		



* 표현식을 유연하게 – 조금 더 향상된 문자열 클래스 정리

표현식	설명
[:digit:]	숫자 의미. [0-9] 혹은 \d
[:alpha:]	영문 대소문자 표현 [A-z] 또는 [A-Za-z]
[:alnum:]	영문, 숫자 표현 [A-z0-9] 또는 \w
[:space:]	공백, 탭, 개행문자 등을 표시
[:punct:]	특수문자 표시 !@#\$%^&*()::<>,{}
[:graph:]	영문자 특수문자 모두를 표시
[:cntrl:]	\n, \r과 같은 제어문자를 표시

4) 정규표현식을 이용하여 불필요한 문자, 특수문자 등을 제거하는 작업을 그림처럼 작업해보죠.



분석목적에 맞게 필요한
정규표현식을 그때그때 알
맞게 이용하면 돼요.

5) 유의미한 명사형 단어들을 추출하고 이들을 벡터형태로 변경하여 각 단어마다 음절이 2 음절 이상인 단어만을 추출하는 동작을 그림처럼 코딩해요.

```
> txt_word<-sapply(txt1,extractNoun,USE.NAMES=F)
> txt_data<-unlist(txt_word)
>
> txt_r<-Filter(function(x){nchar(x)>=2},txt_data)
> head(txt_r,20)
[1] "새해맞이"      "랜덤"          "선물"
[6] "실용템을"      "선택과"        "누구"
[11] "스트레이키"     "예산"          "충분"
[16] "바른정당"      "시의원"        "들이"
> |
```

여러분의 분석 목적에 따라 음절의 개수 조건을
달리해도 되겠죠?

"호기심"	"삼공즈는멤버를을"
"선물"	"갈지내일공개"
"한데"	"자유한국당과"
"극력반대입니다"	"교복"

6) 가장 많이 언급된 단어들만 간추려서 그 결과를 알아보죠. 그림처럼 코딩해보죠.

```
> txt_r<-table(txt_r)
> class(txt_r)
[1] "table"
> head(sort(txt_r,decreasing=T),20)
txt_r
  새해 행복 이벤트 선물 기념 맞이 트친 마음 받으세요 올해 우리
  326 41 30 26 22 22 21 20 18 18
  추첨 새해맞이 인사 진짜 받으세 가요 건강 오늘 대제전
  18 17 17 17 16 14 14 13
> |
```

단어의 빈도수를 계산 → 언급이 많이 된 순서대로 20개를 추출하여 화면에 표시

7) 빈도결과를 시각화 하여 표시하면 더 낫겠죠? 가장 많이 사용하는 wordcloud 형태로 결과를 표시해보죠.

```
> install.packages(c("wordcloud","RColorBrewer"))
경고: 패키지 'wordcloud', 'RColorBrewer'가 사용중이므로 설치되지 않을 것입니다
> library(wordcloud)
> library(RColorBrewer)
> choice_pal<-brewer.pal(8,'Dark2')
> wordcloud(names(txt_r),freq=txt_r,scale=c(6,1),rot.per=0.25,min.freq=7,colors=choice_pal)
> |
```

